

以Agent为核心的具身数字员工构建

LLM进化三部曲：从对话到自主

01 对话交互 Chat Only

- ✓ 核心模式：一问一答，被动响应。
- ✓ 关键技术：提示词工程 (CoT, ReAct) 提升推理；RAG 引入外部知识，解决幻觉。
- ✓ 典型应用：Copilot、情感陪伴、文案创作。

02 工作流编排 Workflow

- ✓ 核心突破：Function Calling & MCP (模型上下文协议)，模型具备使用工具的能力。
- ✓ 关键技术：低/无代码平台 (Coze, Dify) 进行工作流编排。
- ✓ 商业影响：AI应用开发成本降低，各行业加速落地实践。

03 自主智能体 Agent

- ✓ 核心跃迁：从被动响应到主动执行，具备自主性。
- ✓ 关键要素：记忆(Memory)、规划(Planning)、工具(Tools)协同完成复杂目标。
- ✓ 未来形态：类似Devin，成为真正的数字员工，提升生产力。

AI Agent 论文趋势分析

对 ICLR, ICML, NeurIPS 三大顶级AI会议中 Agent 相关论文数量的估算与关键词趋势的可视化分析 (2023-2025)。

Agent相关论文数量估算



Agent核心关键词演进



数据来源：基于对会议论文列表的关键词搜索和趋势分析的估算值。2025年为预测数据。

以Agent为核心的具身数字员工全景图

一个在本地AI PC上运行的、由多个专家Agent构成的、能够与物理和数字世界交互的先进系统。

数字员工能力解构 (The "What")

感知理解 (Perception)

数字世界感知
UI理解 | 文档解析 | 语音识别

物理世界感知
3D环境感知 (SLAM) | 物体识别/跟踪 | 人脸识别 (InsightFace)

认知规划 (Cognition)

角色/行业技能
人事管理 (HR) | 财务分析 | 电商运营 | 投资建议

专业/定制技能
代码编写 | 市场分析 | 健康/时尚咨询 (美妆)

执行交互 (Execution)

数字世界执行
PC/OS操作 | 浏览器操作 | 语言/语音输出

物理世界执行
自主导航/避障 | 智能家居控制 | 物品递送

实现能力的技术架构 (The "How")

多Agent协作系统

任务主Agent

职责: 接收指令, 任务分解, 调度专家Agent。
核心: 强大的规划与协同能力。

专家Agent团队

基础能力: GUI Agent (最上层)
角色专家: 人事Agent, 财务Agent, 运营Agent
领域专家: 编程Agent, 物理Agent, 魔镜Agent

Agent框架与协议

核心框架

自主循环: Plan -> Act -> Observe -> Reflect
代表项目: AutoGPT, Open-Interpreter

通信与工具

上下文协议: MCP
工具调用: Function Calling / ROS

基础模型层

语言模型 (LLM)

模型: Qwen3-30B-A3B

多模态模型 (MLLM)

模型: Qwen2.5-Omni-7B

视觉模型 (VLM)

模型: Qwen2.5VL
物理: YOLO, InsightFace

语音模型

ASR/TTS: FunASR, GPT-SovITS

硬件与基础设施层

核心计算单元

本地主机: AMD AI PC (Windows)
能力: CPU+GPU+NPU混合算力

具身载体

机器人底座: 轮式机器人, 传感器 (LiDAR, Camera, Mic)

构建多Agent协作系统

要实现我们的目标，需要一个灵活的、由多个可插拔的专家Agent构成的协作系统。本章将阐述其核心架构，并引出后续对各类开源Agent的详细调研。

核心架构参考



核心组件调研目录

多Agent框架

这些框架提供了构建主Agent和专家Agent团队所需的基础设施，包括通信、任务管理和生命周期控制。

查看多Agent框架项目对比 ->

GUI Agent

专注于理解和操作图形用户界面 (GUI)，是PC/OS Agent和Mobile Agent的核心感知与执行能力的基础。

查看GUI Agent项目对比 ->

PC/OS级Agent

这类Agent专注于操作系统层面的自动化，能够跨应用执行任务，是实现通用桌面操作能力的关键。

查看PC/OS级Agent项目对比 ->

Browser Agent

特化于Web环境，能够高效地浏览网页、填写表单、抓取数据，是处理一切在线任务的专家。

查看Browser Agent项目对比 ->

Mobile/App Agent

专为移动操作系统 (Android/iOS) 设计，能够像人一样操作手机上的各种App，完成移动端任务。

查看Mobile/App Agent项目对比 ->

开源Agent开发平台

提供了快速构建、调试和部署单个Agent的工具链和组件库，是开发专家Agent的加速器。

查看Agent开发平台对比 ->

领域Agent

这些Agent为解决特定垂直领域问题而生，例如文档理解、PPT生成或机器人操作，是AI技术落地应用的关键体现。

查看领域Agent项目浏览 ->

Agent基座模型

包含LLM, VLM, MLLM, ASR, TTS, CV等。它们是要与Agent认知与感知能力的核心引擎。

查看基座模型与推理框架 ->

Multi-Agent多智能体开源框架对比

项目	核心理念 & 架构	智能体交互模式	核心特点 & 适用场景
Microsoft AutoGen	通用可组合对话框架。将多智能体协作抽象为Agent间的自动聊天，Agent角色、能力和流程高度可定制。	对话驱动。通过中央管理器(GroupChatManager)协调多个Agent (包括人类) 进行轮询或异步的对话。	高度灵活，强大的工具使用和函数调用能力。适合解决需要动态协作的复杂任务，软件开发、科学实验等。
crewAI	面向驱动的自主智能体协作框架。通过定义具有特定角色(Role)、目标(Goal)和工具(Tools)的Agent，并将其组织成一个“团队(Crew)”来协同工作。	任务驱动的策略/单任务流。一个Agent完成任务后，其结果会被传递给下一个Agent执行后续任务，形成清晰的协作链。	结构化、可复现的操作流程。非常适合构建需要多个专业角色按顺序协作完成的重复性 workflows，如市场分析报告、旅行计划等。
Owl (by CAMEL-AI)	Agent即服务(AaaS)编排平台。定位为Agent的“操作系统”，旨在调和和协调不同来源、不同能力的Agent完成宏大任务。	分层任务分发。上层Agent将复杂任务分解，并分发给专门的子Agent或外部工具执行。	宏任务规划与执行。连接异构Agent，适合需要整合多种AI能力的大型项目，如“写一篇完整的行业研报”。
CommonGround	社会模拟平台。构建一个包含大量拥有独立记忆和背景的Agent的虚拟社会，用于观察和研究其交互产生的群体行为。	环境交互。Agent在共享的虚拟环境中互动，其行为由个体动机驱动，产生涌现式的社会动态。	大规模社会动力学模拟。模拟社会科学、市场行为分析、信息传播等领域的研究利器。
MIRIX	动态自适应Agent集群。由一个“主”Agent根据任务需求，在运行时代际创建、修改、组合或销毁工作Agent。	中心化主-客集群模式。主Agent进行元认知和策略调整，工作Agent集群执行具体操作。	系统自适应和演化。旨在探索通往AGI的路径，适合解决需要动态调整策略的开放式、超复杂问题。

GUI自动化Agent开源项目对比

项目	核心技术 (Perception & Action)	运行环境 & 依赖	核心特点 & 适用场景
UI-TARS	VLM驱动 (专注图像/文档识别)。通过在大量UI数据上训练的模型，实现对界面元素的高精度、细粒度定位与识别。	跨平台 (Win/macOS/Linux)，提供即用型模型和部署方案。	工业级UI自动化测试与RPA。其精准的视觉识别能力使其在自动化测试、流程自动化等场景中比通用VLM方法更稳定可靠。
AutoGPTM	LLM/VLM驱动的自启动框架。将GUI操作建模为生成任务，Agent根据历史观察和指令生成下一步动作 (如点击、输入)。	主要面向研究，依赖特定VLM (如 CogVLM) 和训练框架。	探索AGI路径的学术研究。用于复杂的GUI任务，展示了如何从训练一个具备通用GUI操作能力的VLM。
SimpAgent	双智能体架构 (Planner & Controller)。Planner (GPT-4V) 负责高层规划和任务分解，Controller 负责执行具体的点击/输入操作。	跨平台 (Python-based)，依赖GPT-4V等多模态大模型API。	通用GUI自动化。其规划-执行分离的架构思路清晰，逻辑简洁，是研究和学习GUI Agent工作原理的优秀范例。

开源Browser Agent项目对比

项目	核心技术 (Perception)	动作空间 (Action)	核心特点 & 适用场景
browser-use	截图 + 辅助决策树 (Ally Tree)。结合视觉信息和页面的结构化信息，实现端到端的自动化。	通过Playwright执行浏览器原生操作 (点击、输入、滚动等)。	浏览器Agent的开源基准实现。作为研究和二次开发的起点，提供了清晰的基础和可复现的评测标准。
nanobrowser	简化HTML。仅提取页面上可交互的元素 (链接、按钮、输入框)，大幅减少上下文长度。	高级抽象指令，如“click(id)”，Type(id, text)。	极简主义，易于理解和修改。非常适合学习和教学，展示了“少即是多”在Agent设计中的应用。
BrowserOS	截图 + 完整DOM。旨在让Agent获得与人类用户几乎平等的完整页面信息。	通过Playwright执行底层鼠标和键盘操作。	致力于成为浏览器中的“操作系统”。作为一个功能性的Web Copilot，目标宏大，更偏向于一个完整的集成应用。
cuab-browser	自定义CUA树 (Comprehensive Understanding of an Application)。一种为LLM优化的、高度压缩的HTML表示方法。	通过Playwright执行浏览器原生操作。	专注提升效率和降低成本。其创新的CUA树概念有望减少Token消耗，非常适合需要大规模、可扩展部署的商业场景。

PC/OS级自动化Agent开源项目对比

项目	核心技术 (Perception & Action)	多智能体支持	核心特点 & 适用场景
UI-TARS-desktop	VLM驱动 (专注图像识别)。通过在大量UI数据上训练的模型进行UI控制 (无鼠标/键盘) 的识别精度。	不支持	跨平台的桌面UI自动化测试。其精准的控件识别能力使其在自动化测试和RPA场景中较通用VLM更稳定。
open-computer-use	纯VLM驱动。分析屏幕截图，决策后通过系统API执行点击、输入等操作。	不支持	通用桌面自动化研究的开源基准。作为纯视觉方法的简洁实现，是研究和二次开发的优秀起点。
Magnitude	纯VLM驱动。与open-computer-use类似，但更侧重于框架和用户体验，目标是成为开箱即用的“数字伙伴”。	不支持	个人助理式任务。适合非技术用户采用AI仿佛像真人一样完成日常电脑操作。
Microsoft UFO	VLM + UIA混合驱动。同时“看”屏幕和“读”Windows无障碍API，获取UI元素的结构化信息。	原生支持 (双Agent协作)	精准的Windows应用自动化。混合模式比纯视觉更稳定，适合企业环境下的流程自动化 (RPA)。
OS-Copilot	VLM + OS级API混合驱动。通过中央规划器调用文件操作、Web搜索、UI自动化等多种工具。	原生支持 (中心化协作)	构建通用的操作系统级助手。框架设计完善，操作能力较强，旨在成为未来操作系统中的OS Copilot。
BAAI Cradle	复杂知识图谱。包含VLM、自反思、记忆和技能库模块，Agent能从经验中学习和总结技能。	高级单体架构	探索AGI路径的学术研究。尤其适合需要长期学习和适应的超复杂任务 (如玩大型游戏)。
Windows-MCP	VLM + 高级提示工程。核心是其多模态思维链(MCP)提示策略，引导模型进行更精准的操作。	不支持	验证和研究VLM推理极限。展示了优秀的Prompting如何显著提升纯视觉Agent的性能。

Mobile/App Agent开源项目对比

项目	核心技术 (Perception & Action)	多智能体支持	核心特点 & 适用场景
AppAgentX	VLM驱动 + 自主探索与学习。能像人类一样通过观察和尝试来学习如何操作任意App，并形成记忆。	高级单体架构	通用App自动化与研究。旨在实现无需任何人工干预可自主探索并完成复杂App操作的应用智能体。
AppAgent	VLM驱动 + 图形化用户界面 (GUI)。通过分析屏幕截图和UI元素来理解操作意图。	不支持	通用Android App自动化。作为早期探索之一，展示了LLM驱动UI操作的可能性。
AutoDroid	VLM + UI意图树 (xML) 混合驱动。结合视觉信息和UI结构化数据，实现更精准的操作。	不支持	精准的App内多步任务执行。混合模式提高了操作的准确性，适合需要精确点击特定元素的场景。
MobileAgent	VLM + 工具集成。通过接收感知到的UI控件，并将其动态组合成可供VLM调用的工具链 (API)。	不支持	跨应用操作和工具化交互。将UI操作API化的思路非常新颖，为复杂跨应用任务提供了可能。
Android-MCP	VLM + 高级提示工程 (MCP)。将Windows-MCP的多模态思维链提示策略应用于安卓平台。	不支持	研究和提升VLM在移动端的视觉推理能力。专注于通过提示工程挖掘现有VLM的潜力。
DroidRun	Agent评测框架与基准。提供一个安全、可复现的环境来评估Android Agent的性能。	N/A (评测框架)	Android Agent性能评估。对于研究和比较不同Agent方法的优劣至关重要，是该领域的基础设施。
AgentCPM-GUI	通用VLM驱动。一个为通用GUI理解和指令设计的VLM，可应用于桌面和移动端。	不支持	跨平台 (含移动端) 的通用GUI自动化研究。其通用性使其成为一个灵活的基座模型组件。

开源Agent开发平台对比

项目	核心理念 & 定位	构建方式	核心特点 & 适用场景
Qwen-Agent	全栈式Agent框架。覆盖从意图理解到工具调用、规划、推理、反思的全流程。	Python代码为主，提供丰富的部署工具 (如 Code Interpreter) 和多种Agent示例。	与Qwen生态无缝集成。强大的代码解释和工具使用能力，适合需要复杂数据分析和函数调用的任务。
Coze Studio	一站式低代码/无代码Agent开发平台。旨在让任何人都能快速创建、测试和发布AI Bot。	可视化拖拽界面。通过配置工作流节点和插件来构建Agent。	极低的上手门槛。丰富的插件市场。适合产品经理、运营和非专业开发者快速构建和部署智能应用。
JoyAgent	面向复杂任务的企业级多智能体系统。采用规划-工具-执行的分层自治架构。	代码定义为主。遵循其特定的分层架构进行开发。	海量工具调用和复杂业务流程设计。适合电商、物流等需要大规模、高可靠Agent的企业级场景。
LangChain	LLM应用开发的“事实标准”框架。提供了一套模块化的组件来构建上下文化应用。	模块化编程 (Python/JS)。通过组合Chains和Components来构建。	生态最成熟，社区最庞大。灵活性极高。几乎是所有复杂Agent应用的底层基础，适合专业开发者。
FlowiseAI	LangChain的低代码可视化封装。将LangChain的组件和链多封装为可视化的节点。	可视化拖拽界面。节点直接映射到LangChain的组件。	极大地降低了LangChain的使用门槛。适合快速搭建原型、学习LangChain概念和构建简单应用。
Eko	开源的AI工作流自动化平台。类似开源版的Copilot或n8n，专注于可视化编排。	可视化DAG图编排。通过连接不同功能的节点创建工作流。	注重工作流的可视化编排和执行。支持定时触发和Webhook，适合构建内部工具和自动化流程。
12-Factor Agents	一套构建“可靠、可扩展Agent”的架构方法论。类似于“十二要素应用”宣言。	架构指导原则。不提供具体代码框架，而是定义了工程最佳实践。	强调测试分离、可观测性、配置管理等。适合大型、严肃的Agent项目的架构设计。

领域Agent开源项目巡览

领域	项目	核心能力 & 简介
文档理解	RAGflow	基于复杂非结构化文档和工作流，能对复杂非结构化数据进行“极深”的提问和解析。
PPT生成	PPTAgent, MultiAgentPPT	通过一句话生成关键词，自动生成内容生成、排版设计和图文匹配，一键生成完整PPT。
深度研究	local-deep-research	本地化运行的自主研究员Agent，围绕一个主题进行深度信息检索、分析、整合并生成研究报告。
科研辅助	AgentLaboratory	旨在自动化科学研究过程的Agent。可用于运行模拟实验、分析数据并尝试解释实验结果。
图像创作	Pixelie-MCP	一个多智能体协作绘画系统，能够理解复杂的图像描述性提示，并协同生成高质量的图像创作。
短视频生成	ShortGPT	自动化的短视频生成创作框架，能生成短视频脚本、AI配音、素材匹配和字幕。
模拟面试	FaolUp	一个AI驱动的面面试试平台，能够提供实时的面试练习、追问和表现反馈。
机器人操作	Manipulate Anything	基于多模态大模型的机器人Agent，使其能够理解高层指令并直接操作现实世界或模拟环境中的任意物体。

Agent基座模型及推理框架

语言大模型 (LLM)

Qwen3-30B-A3B

视觉语言模型 (VLM)

Qwen2.5VL

多模态大模型 (MLLM)

Qwen2.5-Omni-72B

语音处理 (Speech)

FunASR | GPT-SovITS

计算机视觉 (Vision)

InsightFace | YOLO

记忆体 (Memory)

KV-Cache | VectorDB | GraphDB

推理框架 (Inference)

Ollama | llama.cpp | ONNX Runtime | MNN

保存为PDF